论文精读 · 六部分完整讲解

大语言模型评测：任务、基准与方法

A Survey on Evaluation of Large Language Models

评什么 / 在哪里评 / 怎么评：从能力测量到可信评测

论文信息

Yupeng Chang、Xu Wang等16位作者；正式期刊为ACM Transactions on Intelligent Systems and Technology（2024），DOI：10.1145/3641289。

讲解底本

内容以用户提供的arXiv:2307.03109v9（2023-12-29）为准；覆盖原文3幅图、10张表，密集图表附放大讲解。

核心主张

评测应是一门支撑模型发展的独立学科。既要识别任务能力，也要揭示安全风险、失败条件和改进方向。

底本：arXiv 2307.03109v9 · 45页 · 原文图1–3、表1–10全覆盖

六部分结构：从评测问题走到研究挑战

以what / where / how贯穿全文，而不是把研究文献简单堆叠。

01

01—02｜背景与测量对象

第一部分：研究背景、贡献与三维框架。第二部分：自然语言处理、推理、生成、多语言、事实性与安全。

02

03—04｜应用与基准

第三部分：社会科学、自然科学、工程、医疗、Agent与其他应用。第四部分：通用、下游和多模态基准。

03

05—06｜方法与总结

第五部分：自动指标与人类评价。第六部分：成功失败、协议演进、七项挑战与作者结论。

图2：评测研究增长，是本文的背景而非性能证据

作者观察到2023年评测文献快速增加，但测量体系仍缺少整体梳理。

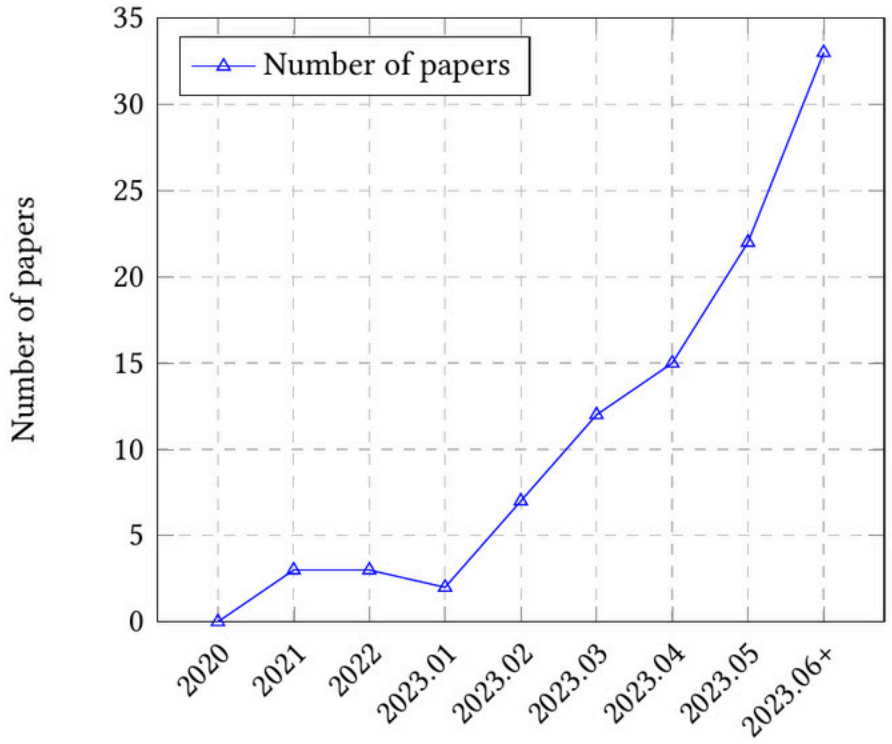

Fig. 2. Trend of LLMs evaluation papers over time (2020 - Jun. 2023, including Jul. 2023.).

图怎么读

横轴含2020—2022年度与2023年月度节点；纵轴为论文数。上半年末端节点明显增加，末端标2023.06+、图注包含7月，并非全年趋势。

它支持什么

LLM发展促使研究者从推理、鲁棒性、可信性、医疗等不同角度评测；跨任务与跨协议的综述因而有必要。

不能怎么解释

年度与月度时间粒度混排，不应计算等间隔增长率；这不是模型准确率曲线，也不能据此判断哪个模型领先。

论文贡献：给评测建立一个可检索的坐标系

本文的原创价值是组织和综合证据，而不是重新训练或统一复测模型。

三维结构

01 解释与证据

以what to evaluate、where to evaluate、how to evaluate整理LLM评测。任务决定对象，基准提供载体，协议决定测量过程。

证据综合

02 解释与证据

汇总多个领域的评测研究，归纳任务依赖的成功与失败；第4节整理46个基准，第5节总结自动与人工评价。

面向未来

03 解释与证据

讨论更完整的行为评测、鲁棒性、动态测试与评测可信性，并强调打分之后应进一步诊断与增强模型。

介绍贡献时要避免把综述当成全模型横向实验。作者没有把所有数据集统一跑一遍，而是梳理各原始论文的证据；因此后面的数值都需要带着任务、模型和数据集条件理解。

图1：全文结构总览，先看主干再看文献叶节点

这幅树状图把“任务—基准—方法—总结—挑战”连接为一个整体。

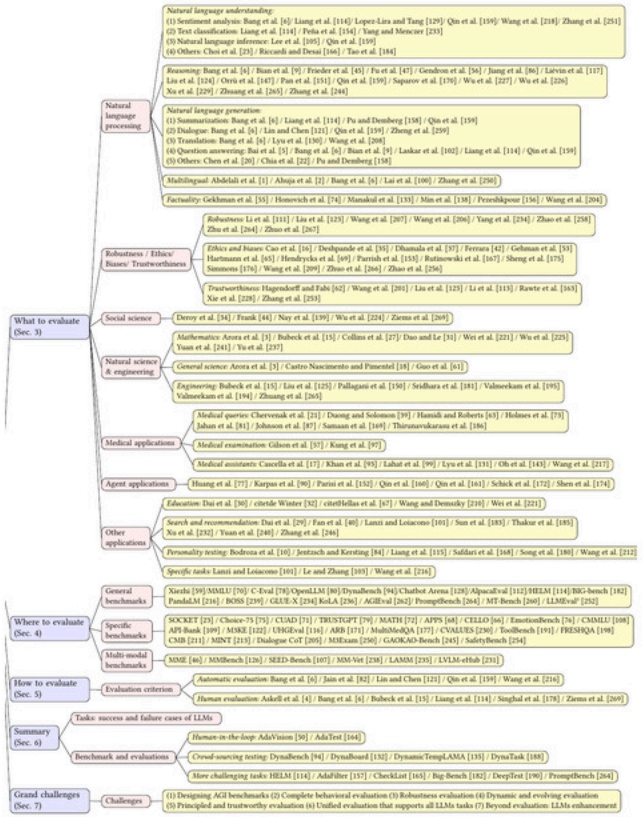

Fig. 1. Structure of this paper.

主干结构

what覆盖NLP、安全与可信性、社会科学、科学工程、医疗、Agent和其他应用；where与how分别整理基准和指标。

叶节点含义

每个细分任务后面的姓名与引用编号是该主题的代表研究索引。它们不是算法步骤，也不是模型的性能排名。

后续阅读

原图完整保留在左侧；接下来分上下区域放大，分别讲测量对象与测量载体、方法和挑战。

图1放大①：what把能力与安全放在同一评测版图

自然语言任务是起点；可靠部署还要回答事实、偏见和鲁棒性问题。

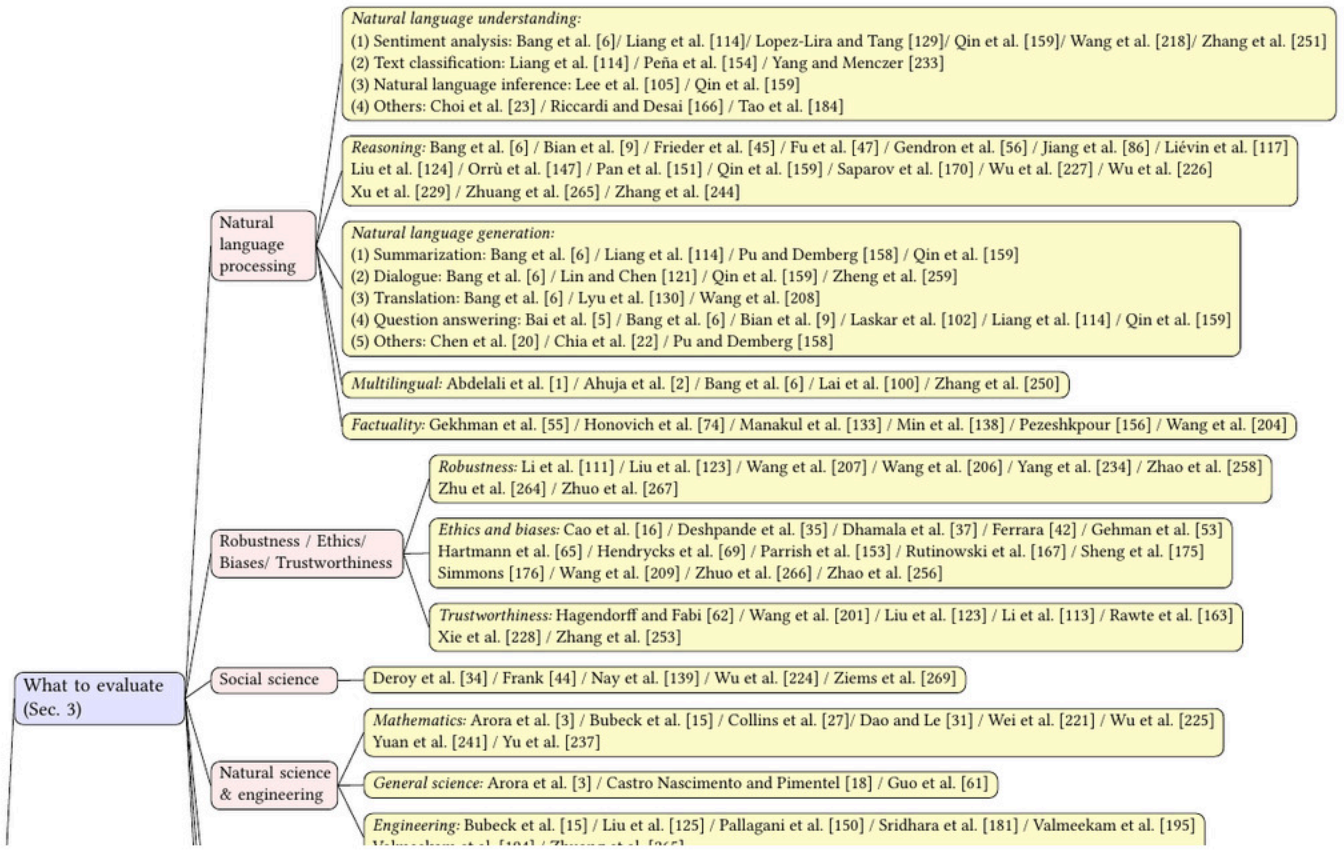

能力主线

理解、推理、生成、多语言、事实性形成NLP板块。每一项又分为若干任务，避免只用一个“语言能力”总分。

风险主线

鲁棒性、伦理与偏见、可信性具有交叉关系。答对正常问题，不意味着对抗输入下仍正确；表达流畅也不保证事实准确。

跨域主线

社会科学、自然科学与工程继续展开。它们说明模型能力必须放到具体任务、领域知识和评测条件中判断。

图1上半区 | PDF p.3 | 图表为原文；中文为汇报解读

图1放大②：where与how决定能力证据怎样产生

同样的模型，换任务、数据或评分程序，得到的结论可能不同。

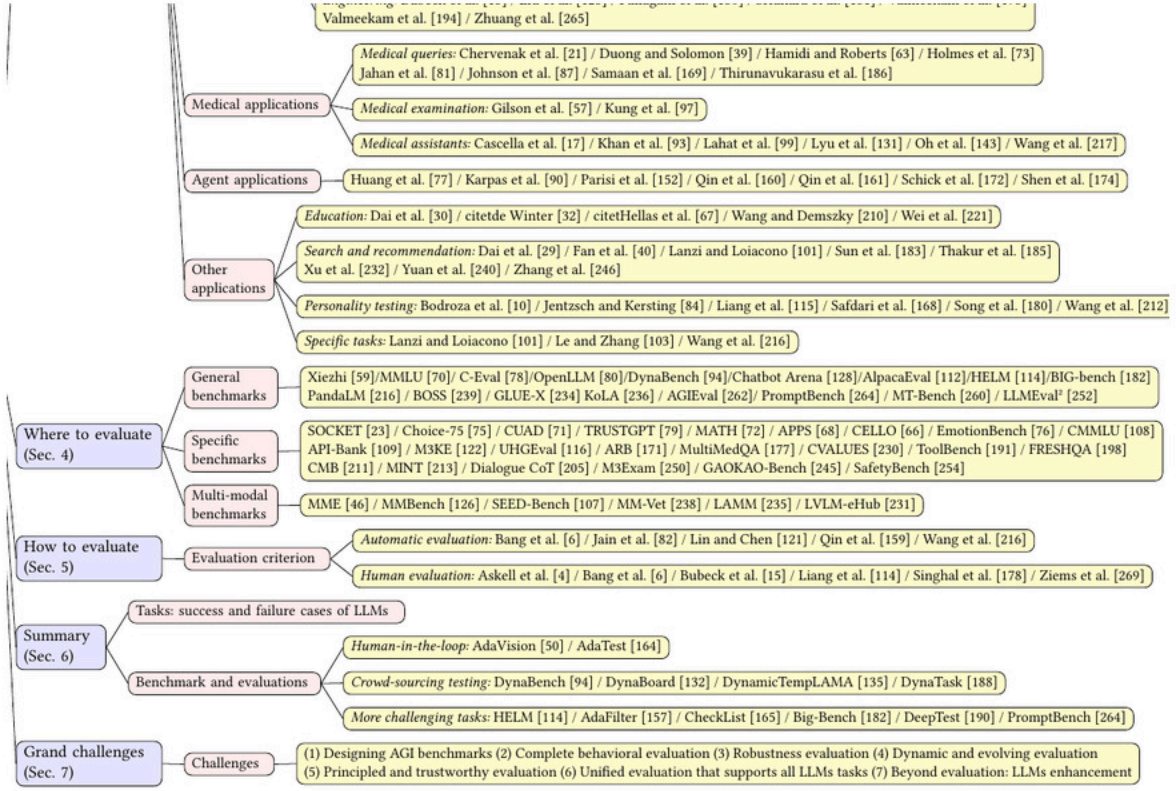

Fig. 1. Structure of this paper.

应用边界

医疗、Agent和其他应用把语言能力带入行业使用；测试的对象从单句回答走向工具调用与实际任务。

基准与方法

通用、下游、多模态基准对应不同数据载体；自动与人工评价对应不同判断方式，两者均需要明确标准。

总结与挑战

图的末端是成功失败、协议演进和未来挑战。作者希望评测能形成诊断与改进，而非停留在排行榜。

LLM基础：预测下一个词元，不等于理解全部任务

Transformer、上下文学习与RLHF解释能力来源，但不能代替能力评测。

生成机制

01 解释与证据

自回归模型逐词元生成：$P(y|X) = \prod P(y_t \mid X, y_1, \cdots, y_{(t-1)})$。序列概率由逐步条件概率组成，不是一个安全分数。

使用机制

02 解释与证据

提示工程决定输入任务；上下文学习使模型利用示例与语境；RLHF以人类反馈优化输出，改变交互行为。

评测含义

03 解释与证据

提示、任务形式和生成条件会影响输出。即使架构或参数规模增加，也必须用具体任务验证能力、风险与可靠性。

这里只补够理解评测所需的技术背景。公式强调模型按条件概率生成，不意味着它的置信度自动等于事实正确率。提示和反馈会改变表现，因此评测时必须注意交互方式。

表1：传统ML、深度学习与LLM的概括比较

规模和自动化能力提高，同时带来资源需求与可解释性的压力。

Table 1. Comparison of Traditional ML, Deep Learning, and LLMs

Comparison	Traditional ML	Deep Learning	LLMs
Training Data Size	Large	Large	Very large
Feature Engineering	Manual	Automatic	Automatic
Model Complexity	Limited	Complex	Very Complex
Interpretability	Good	Poor	Poorer
Performance	Moderate	High	Highest
Hardware Requirements	Low	High	Very High

行列怎么读

列对应三类模型，行对应数据规模、特征工程、复杂度、可解释性、表现和硬件需求。逐行对比，不要把行当成实验结果。

主要变化

传统ML较依赖手工特征，深度学习和LLM自动提取特征；LLM使用更大数据、模型和硬件，解释模型行为更加困难。

证据边界

表中Highest等措辞是作者的概括性描述，不是统一数据集上的严格优胜证明；后面的跨任务评测正是为了细化这种概括。

图3：模型→任务→数据→过程，三个问题缺一不可

what规定测量对象，where规定样本，how规定评价程序。

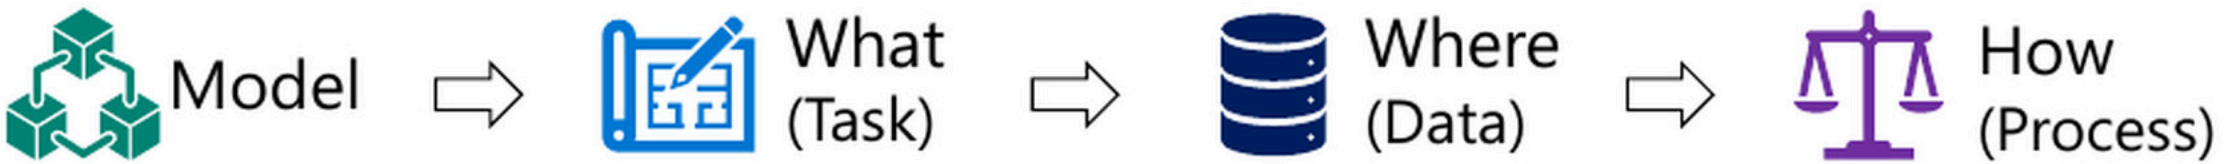

Fig. 3. The evaluation process of AI models.

任务｜What

先明确要测什么，例如分类、生成、推理或鲁棒性。能力标签过宽，会导致结果难以解释。

数据｜Where

用数据集和基准把任务转成可检验样本。数据覆盖面、分布和时效会影响结论能否外推。

过程｜How

选择自动指标、人类评价和测试协议。传统交叉验证、留出法等提供背景，但LLM还需要新的评价设计。

表2：NLP评测覆盖矩阵，不是能力排行榜

勾号表示引用研究覆盖某类任务；空白不等于模型失败。

Table 2. Summary of evaluation on **natural language processing** tasks: NLU (Natural Language Understanding, including SA (Sentiment Analysis), TC (Text Classification), NLI (Natural Language Inference) and other NLU tasks), Reasoning, NLG (Natural Language Generation, including Summ. (Summarization), Dlg. (Dialogue), Tran (Translation), QA (Question Answering) and other NLG tasks), and Multilingual tasks (ordered by the name of the first author).

Reference	NLU				RNG.	NLG					Mul.
	SA	TC	NLI	Others		Summ.	Dlg.	Tran.	QA	Others	
Abdelali et al. [1]											✓
Ahuja et al. [2]											✓
Bian et al. [9]					✓				✓		
Bang et al. [6]	✓				✓	✓	✓	✓	✓		✓
Bai et al. [5]									✓		
Chen et al. [20]										✓	
Choi et al. [23]				✓							
Chia et al. [22]										✓	
Frieder et al. [45]					✓						
Fu et al. [47]					✓						
Gekhman et al. [55]						✓					
Gendron et al. [56]					✓						
Honovich et al. [74]			✓			✓	✓			✓	
Jiang et al. [86]					✓						
Lai et al. [100]											✓
Laskar et al. [102]	✓		✓		✓	✓		✓	✓	✓	✓
Lopez-Lira and Tang [129]	✓										
Liang et al. [114]	✓	✓				✓			✓		
Lee et al. [105]			✓								
Lin and Chen [121]							✓				
Liévin et al. [117]					✓						
Liu et al. [124]					✓						
Lyu et al. [130]									✓		
Manakul et al. [133]									✓	✓	
Min et al. [138]										✓	
Orrù et al. [147]					✓						
Pan et al. [151]					✓						
Peña et al. [154]		✓									
Pu and Demberg [158]						✓				✓	
Pezeshkpour [156]										✓	
Qin et al. [159]	✓		✓		✓	✓	✓		✓		
Riccardi and Desai [166]				✓							
Saparov et al. [170]					✓						
Tao et al. [184]				✓							
Wang et al. [208]								✓			
Wang et al. [218]	✓										
Wang et al. [204]			✓						✓		
Wu et al. [227]					✓						
Wu et al. [226]					✓						
Xu et al. [229]					✓						
Yang and Menczer [233]		✓									
Zheng et al. [259]							✓				
Zhang et al. [251]	✓										
Zhang et al. [250]											✓
Zhuang et al. [265]					✓						
Zhang et al. [244]					✓						

列的含义

NLU分情感分析SA、分类TC、推断NLI及其他；RNG是推理；NLG分摘要、对话、翻译、问答及其他；Mul为多语言。

行的含义

每行是一项文献，按第一作者排列。一个研究可覆盖多个任务；多处勾号显示任务的交叉性。

阅读方法

先看哪些研究覆盖目标任务，再回到原文条件理解结果。事实性虽在3.1.5讨论，但没有独立列出在表2。

表2放大①：理解、推理和生成的任务交叉

同一篇研究往往同时检查几个维度，而不是只测一种能力。

Reference	NLU				RNG.	NLG					Mul.
	SA	TC	NLI	Others		Summ.	Dlg.	Tran.	QA	Others	
Abdelali et al. [1]											✓
Ahuja et al. [2]											✓
Bian et al. [9]					✓				✓		
Bang et al. [6]	✓				✓	✓	✓	✓	✓		✓
Bai et al. [5]									✓		
Chen et al. [20]										✓	
Choi et al. [23]				✓							
Chia et al. [22]										✓	
Frieder et al. [45]					✓						
Fu et al. [47]					✓						
Gekhman et al. [55]						✓					
Gendron et al. [56]					✓						
Honovich et al. [74]			✓			✓	✓			✓	
Jiang et al. [86]					✓						
Lai et al. [100]											✓

观察左侧

Abdelali与Ahuja侧重多语言，Bang覆盖多类任务；这些行说明评测可能同时涉及推理、摘要、翻译与问答。

观察中间

NLU子列细分“理解”；RNG单列提示推理不是情感判断；NLG下不同任务也不能用一种质量标准。

应当记住

选择评测数据前先说清任务范围。一个通用模型的优势可能集中于生成，而非所有理解和推理任务。

表2放大②：不同生成任务使用不同评价证据

对话流畅、摘要忠实和问答正确，是三个不同问题。

Jiang et al. [86]					✓						
Lai et al. [100]											✓
Laskar et al. [102]	✓		✓		✓	✓		✓	✓	✓	✓
Lopez-Lira and Tang [129]	✓										
Liang et al. [114]	✓	✓				✓			✓		
Lee et al. [105]			✓								
Lin and Chen [121]							✓				
Liévin et al. [117]					✓						
Liu et al. [124]					✓						
Lyu et al. [130]									✓		
Manakul et al. [133]									✓	✓	
Min et al. [138]										✓	
Orrù et al. [147]					✓						
Pan et al. [151]					✓						
Peña et al. [154]		✓									
Pu and Demberg [158]						✓				✓	
Pezeshkpour [156]										✓	

生成维度

Summ、Dlg、Tran、QA分别对应摘要、对话、翻译和问答。一个模型在其中表现好，不保证在其余任务上同样可靠。

代表索引

Liang覆盖多个任务，Honovich等研究与摘要、对话及事实相关；各行可作为继续查找原始评测的入口。

解释边界

表里没有模型版本、样本量或分数。这些信息必须从正文和被引用的原始研究中取得，不能从勾号推断。

表2放大③：语言与推理覆盖并不均衡

综述中的研究重点分布，不能代表所有语言和应用均已被充分测试。

Pu and Demberg [158]						✓				✓	
Pezeshkpour [156]										✓	
Qin et al. [159]	✓		✓		✓	✓	✓		✓		
Riccardi and Desai [166]				✓							
Saparov et al. [170]					✓						
Tao et al. [184]				✓							
Wang et al. [208]								✓			
Wang et al. [218]	✓										
Wang et al. [204]			✓						✓		
Wu et al. [227]					✓						
Wu et al. [226]					✓						
Xu et al. [229]					✓						
Yang and Menczer [233]		✓									
Zheng et al. [259]							✓				
Zhang et al. [251]	✓										
Zhang et al. [250]											✓
Zhuang et al. [265]					✓						
Zhang et al. [244]					✓						

推理研究

多个Wu、Xu、Zhuang、Zhang等引用集中于RNG列，说明推理是重要评测主题，但任务复杂度仍各不相同。

多语言研究

Mul列由部分研究覆盖。总体表现必须结合语言脚本、训练资源和任务适配解释。

避免误读

这是一张文献地图而不是总体统计抽样。研究数量多的领域不必然更成熟，也不代表该领域风险更高。

自然语言理解：情感与分类较强，语义边界仍有限

“能给文本贴标签”与“能理解复杂意义”不能画等号。

01 情感与分类

引用研究常报告较好的情感分析和分类表现；Liang的特定分类评测中GLM-130B准确率85.8%，不是全任务平均成绩。

02 推断与语义

NLI要求判断前提与假设关系；模型难以表达人的意见分歧。事件语义相似性、无意义短语识别等仍显示不足。

03 任务适配

Choi引用研究中微调BERT可超过更大零样本模型的社会知识表现。模型规模不能替代专门任务验证。

推理：算术与逻辑进步，不代表抽象推理全面可靠

必须区分数学、常识、符号、空间、多步和分布外推理。

01 已有优势

引用研究中ChatGPT的算术相对GPT-3.5进步；ChatGPT和GPT-4在部分逻辑测试优于传统微调方法。

02 主要失败

符号、空间、多跳和复杂抽象任务仍有困难；反事实变化可能使模型失去原有表现，说明泛化与熟悉题目不同。

03 评价原则

逐步推理输出只是可观察行为。应检查最终正确性、题目变化和任务条件，不能仅凭解释完整认定推理可靠。

讲推理时避免只看模型能否写出很长的步骤。作者列出了多种推理，说明每种都有不同难度。局部成功与抽象、多跳、分布外失败可以并存，这也是综合评测必要的原因。

自然语言生成：质量取决于任务，而非“写得像人”

摘要、对话、翻译、问答和风格迁移，需要分别定义成功。

01 摘要与对话

TNLG v2在某摘要评测领先，ChatGPT表现一般；Claude和ChatGPT在部分对话中强于GPT-3.5，但专门微调模型仍可领先。

02 翻译与问答

人工评价中翻译可较强，但英译其他语言和对比测试有不足；一般知识问答进步，常识问答仍有缺口。

03 写作与风格

生成通常流畅，但正式程度控制、特殊写作和文本质量判断各有边界；读起来顺畅不等于忠实、正确或无偏。

多语言：英语优势不能直接外推到低资源语言

语言脚本、训练数据和文化背景都会改变评测结论。

主要观察

01 解释与证据

阿拉伯语零样本、非拉丁文字和低资源语言任务表现不足；模型对英语的适配通常更充分。

简单补救的限制

02 解释与证据

先译成英语、使用英语提示，也不能稳定追平专用SOTA。翻译可能改变任务信息，无法消除全部语言差异。

研究含义

03 解释与证据

多语言评测应分别报告各语言与任务，关注语言公平和文化偏向；不能用英文榜单代表中文或所有语言能力。

用英语提问可能提高部分结果，但它不是普适解决方案。作者认为低资源和非拉丁语言需要单独评测，因此语言是测量条件，而不是一个可忽略的外观变化。

事实性：回答流畅与事实成立，是不同测量对象

真实性、摘要一致性和原子事实正确性，需要不同证据。

01 测什么

问答检查与现实事实是否一致，摘要检查是否忠于原文；FactScore等将回答拆成原子事实逐项评价。

02 引用发现

Wang等引用研究中GPT-4和BingChat答对超过80%的问题，但仍未达到完全准确；该比例只适用于其特定问答集。

03 尚存缺口

NLI、问答式评估、似然与熵可互补，但缺少统一比较框架；扩大模型不一定提高真实性，估计器本身也须检验。

事实性可用“账单逐项核对”类比：一段回答里有多条可验证陈述，不能因为整体读起来合理就算正确。作者列出不同估计方法，但没有证明一种方法解决所有事实问题。

表3：把鲁棒性、伦理偏见与可信性分开读

这些风险彼此交叉，但正常准确率无法覆盖它们。

Table 3. Summary of LLMs evaluation on **robustness, ethics, biases, and trustworthiness** (ordered by the name of the first author).

Reference	Robustness	Ethics and biases	Trustworthiness
Cao et al. [16]		✓	
Dhamala et al. [37]		✓	
Deshpande et al. [35]		✓	
Ferrara [42]		✓	
Gehman et al. [53]		✓	
Hartmann et al. [65]		✓	
Hendrycks et al. [69]		✓	
Hagendorff and Fabi [62]			✓
Li et al. [111]	✓		
Liu et al. [123]	✓		
Liu et al. [123]			✓
Li et al. [113]			✓
Parrish et al. [153]		✓	
Rutinowski et al. [167]		✓	
Rawte et al. [163]			✓
Sheng et al. [175]		✓	
Simmons [176]		✓	
Wang et al. [207]	✓		
Wang et al. [206]	✓		
Wang et al. [201]	✓	✓	✓
Wang et al. [209]		✓	
Xie et al. [228]			✓
Yang et al. [234]	✓		
Zhao et al. [258]	✓		
Zhuo et al. [267]	✓		
Zhu et al. [264]	✓		
Zhuo et al. [266]		✓	
Zhang et al. [253]			✓

表怎么读

三列分别是Robustness、Ethics and biases、Trustworthiness；每行仍是一项引用研究，勾号不是安全分。

三种问题

鲁棒性问扰动下是否稳定；伦理偏见问是否产生不当差异或伤害；可信性还包含隐私、公平、判断一致性与幻觉。

读表提醒

部分文献跨列；表中Liu[123]重复列示，不能简单按行计独立研究数。更不应把空白解释成“没有风险”。

鲁棒性：正常样本成功，遇到扰动仍可能失守

对抗输入、分布变化和视觉扰动，需要独立压力测试。

测试载体

01 解释与证据

AdvGLUE、ANLI、DDXPlus及扩展GLUE检查分布外或对抗表现；不能只重复常规测试。

提示攻击

02 解释与证据

PromptBench从字符、词、句和语义层攻击提示，说明改变任务表达就可能影响结果；视觉攻击也可能迁移。

总结边界

03 解释与证据

论文引用的证据指向脆弱性，但攻击难度、预算和样本条件各异。没有统一条件时，ASR之间不可随意比较。

用“晴天行车与雨天测试”解释正常性能和鲁棒性：一个模型平时答得对，不代表遇到异常文本、陌生分布或视觉干扰仍可靠。评测需要覆盖这些压力条件。

伦理与可信性：对齐改善与攻击脆弱可能同时存在

更少毒性或更好标准分数，不意味着风险已被全部消除。

01 伦理与偏见

训练数据中的偏见可被继承和放大；角色扮演研究中毒性最高增至六倍。政治、人格和道德问卷仅反映特定测试。

02 可信性多维

DecodingTrust同时检查毒性、刻板印象、鲁棒性、隐私、机器伦理和公平；各维度不能被一个概念替代。

03 条件性判断

GPT-4在标准评测更可信，但在引用研究中也可能更易受攻击；初始正确判断会被质疑或误导，视觉幻觉同样存在。

跨领域应用：能力评测必须接到具体用途

社会科学的解释、工程执行和医疗判断，承担不同后果。

01

社会科学

立场、情感和错误信息分类较强；隐性仇恨等任务部分准确率低于40%。法律判决摘要仍有不连贯和幻觉，税法表现尚未达专家水平。

02

自然与工程

数学、化学、代码和规划对知识与步骤有不同要求。能解释概念，不等于能完成高难证明或可靠工程执行。

03

医疗与Agent

查询、考试、助手及工具调用分别具有不同成功标准；不能用一个问答表现推断临床或外部行动安全。

表4：自然科学与工程的三类研究覆盖

数学、一般科学和工程形成不同任务簇，勾号不代表成熟度。

Table 4. Summary of evaluations on **natural science and engineering tasks** based on three aspects: Mathematics, General science and Engineering (ordered by the name of the first author).

Reference	Mathematics	General science	Engineering
Arora et al. [3]	✓	✓	
Bubeck et al. [15]	✓		✓
Castro Nascimento and Pimentel [18]		✓	
Collins et al. [27]	✓		
Dao and Le [31]	✓		
Guo et al. [61]		✓	
Liu et al. [125]			✓
Pallagani et al. [150]			✓
Sridhara et al. [181]			✓
Valmeekam et al. [194]			✓
Valmeekam et al. [195]			✓
Wei et al. [221]	✓		
Wu et al. [225]	✓		
Yuan et al. [241]	✓		
Yu et al. [237]	✓		
Zhuang et al. [265]			✓

表怎么读

三列对应Mathematics、General science、Engineering。按引用研究定位领域，不能比较各领域模型“平均能力”。

数学证据

基础加减较强，除法、幂、三角函数和长表达式更难；引用研究中高认知层级任务准确率明显下降。

不能外推

单套竞赛题或一类科学问答的成功，无法证明科研能力。第3.4节明确区分数学、一般科学和代码规划。

表4 | PDF p.16；3.4 | pp.16–17 | 图表为原文；中文为汇报解读

科学与工程：专门任务进步，但复杂执行仍不稳定

研究工具的可用性，应以任务检验，而不是以语言流畅性判断。

01 科学知识

五项化学任务准确率介于25%—100%，范围本身显示任务差异。物理与化学比较仅来自有限研究。

02 代码与软件

代码生成和解释有竞争力，但数据结构、树、图论较难；漏洞检测、测试优先级等软件工程任务仍不可靠。

03 规划与执行

常识规划即使在简单任务上也可能失败，泛化能力有限；微调CodeT5在引用研究的规划领域表现最佳，不能只按模型代际推断。

表5：医疗查询、考试与助手，必须分开评价

会回答医学知识题，不代表能安全替代临床专家。

Table 5. Summary of evaluations on **medical applications** based on the three aspects: Medical queries, Medical assistants, and Medical examination (ordered by the name of the first author).

Reference	Medical queries	Medical examination	Medical assistants
Cascella et al. [17]			✓
Chervenak et al. [21]	✓		
Duong and Solomon [39]	✓		
Gilson et al. [57]		✓	
Hamidi and Roberts [63]	✓		
Holmes et al. [73]	✓		
Jahan et al. [81]	✓		
Johnson et al. [87]	✓		
Khan et al. [93]			✓
Kung et al. [97]		✓	
Lahat et al. [99]			✓
Lyu et al. [131]			✓
Oh et al. [143]			✓
Samaan et al. [169]	✓		
Thirunavukarasu et al. [186]	✓		
Wang et al. [217]			✓

行列含义

列序为Medical queries、Medical examination、Medical assistants；标题列举顺序不同，应以实际表头为准。

证据类型

查询评测关注知识信息；考试评测关注标准题正确性；助手评测还需面对患者沟通、临床流程和引用可靠性。

关键边界

这些研究是在不同数据和使用方式下验证潜力。不能把“接近USMLE及格线”写成“具备自主临床能力”。

医疗应用：信息可用，但不确定性和误诊仍是边界

查询、解释与辅助的价值，需要和错误风险一起评价。

01 查询与考试

遗传学、放疗物理和生物医学回答相对准确；初级保健评测也有未及格结果。USMLE表现支持教育潜力，不等于临床替代。

02 医疗助手

报告通俗化和教育辅助显示可行性；手术信息引用研究中GPT-3.5/4准确率46.8%/76.4%，仅限该具体评测。

03 风险限制

引用不足、编造、回答不确定性、误诊和患者隐私仍限制使用。本文没有开展新临床试验。

讲这页时把潜力和边界放在同一条论证中。原文并不否认医疗辅助价值，而是提醒知识正确率不能覆盖误诊、隐私和临床后果。数值必须带上原始任务条件。

Agent应用：模型开始调用工具，评价对象也随之改变

外部API、模型协作与交互流程扩展能力，但也增加评价难度。

代表路线

01 解释与证据

Toolformer学习API调用，TALM通过迭代改进，MRKL连接模块，HuggingGPT协调其他模型；ToolLLM等服务工具应用。

从回答到行动

02 解释与证据

评价不再只看最终文字，还需要理解工具选择、调用时机、交互及任务结果；这是对原文系统路线的讲解。

本文范围

03 解释与证据

该节主要介绍代表框架与能力扩展，没有统一Agent排行榜，也没有证明各系统能完成所有复杂任务。

可以把Agent类比为“从答题学生变成要操作设备的助理”。调用工具以后，仅看最终回答就可能漏掉过程错误。不过本文这一节主要是路线介绍，不是统一Agent评测实验。

表6：其他应用包括教育、推荐、人格与特定任务

应用覆盖越广，越需要明确评价目标和失败后果。

Table 6. Summary of evaluations on **other applications** based on the four aspects: Education, Search and recommendation, Personality testing and Specific applications (ordered by the name of the first author).

Reference	Education	Search and recommendation	Personality testing	Specific applications
Bodroza et al. [10]			✓	
Dai et al. [30]	✓			
de Winter [32]	✓			
Dai et al. [29]		✓		
Fan et al. [40]		✓		
Hellas et al. [67]	✓			
Jentzsch and Kersting [84]			✓	
Lanzi and Loiacono [101]				✓
Le and Zhang [103]				✓
Li et al. [110]		✓		
Liang et al. [115]			✓	
Sun et al. [183]		✓		
Song et al. [180]			✓	
Safdari et al. [168]			✓	
Thakur et al. [185]		✓		
Wang and Demszky [210]	✓			
Wang et al. [212]			✓	
Wang et al. [216]				✓
Xu et al. [232]		✓		
Yuan et al. [240]		✓		
Zhang et al. [246]		✓		

表怎么读

四列分别为Education、Search and recommendation、Personality testing、Specific applications；勾号仅标文献归属。

典型用途

教育关注反馈与考试；搜索推荐关注检索与个性化；人格测试关注回答一致性、情绪与心理测量。

其他应用

游戏设计、日志解析、模型性能评估等也被纳入。表只是整理研究，未提供跨应用统一比较分数。

其他应用的启示：看见效果，也要审查测量过程

教育反馈、推荐效率和心理测量都存在可信边界。

01 教育测量

模型可辅助反馈与问题解释。本文指出某MIT考试引用研究把正确答案放入提示，导致结果不公平，说明要审查协议。

02 检索与推荐

部分实验中ChatGPT组用时更少，推荐可辅助冷启动与解释；不公平推荐仍要求单独检验。

03 人格与特定任务

人格回答存在偏差和一致性问题；模型得分像人类，不代表具有相同心理机制。游戏与日志任务也需专门标准。

表7：46个基准构成测量载体，而非单一总榜

先确定任务焦点和标准，再选择合适基准。

Table 7. Summary of existing LLMs evaluation benchmarks (ordered by the name of the first author).

Benchmark	Focus	Domain	Evaluation Criteria
SOCKET [23]	Social knowledge	Specific downstream task	Social language understanding
MME [46]	Multimodal LLMs	Multi-modal task	Ability of perception and cognition
Xiezhi [59]	Comprehensive domain knowledge	General language task	Overall performance across multiple benchmarks
Choice-75 [75]	Script learning	Specific downstream task	Overall performance of LLMs
CUAD [71]	Legal contract review	Specific downstream task	Legal contract understanding
TRUSTGPT [79]	Ethic	Specific downstream task	Toxicity, bias, and value-alignment
MMLU [70]	Text models	General language task	Multitask accuracy
MATH [72]	Mathematical problem	Specific downstream task	Mathematical ability
APPS [68]	Coding challenge competence	Specific downstream task	Code generation ability
CELLO [66]	Complex instructions	Specific downstream task	Four designated evaluation criteria
C-Eval [78]	Chinese evaluation	General language task	52 Exams in a Chinese context
EmotionBench [76]	Empathy ability	Specific downstream task	Emotional changes
OpenLLM [80]	Chatbots	General language task	Leaderboard rankings
DynaBench [94]	Dynamic evaluation	General language task	NLI, QA, sentiment, and hate speech
Chatbot Arena [128]	Chat assistants	General language task	Crowdsourcing and Elo rating system
AlpacaEval [112]	Automated evaluation	General language task	Metrics, robustness, and diversity
CMMLU [108]	Chinese multi-tasking	Specific downstream task	Multi-task language understanding capabilities
HELM [114]	Holistic evaluation	General language task	Multi-metric
API-Bank [109]	Tool utilization	Specific downstream task	API call, retrieval, and planning
M3KE [122]	Multi-task	Specific downstream task	Multi-task accuracy
MMBench [126]	Large vision-language models(LVLMs)	Multi-modal task	Multifaceted capabilities of VLMs
SEED-Bench [107]	Multimodal Large Language Models	Multi-modal task	Generative understanding of MLLMs
UHGEval [116]	Hallucination of Chinese LLMs	Specific downstream task	Form, metric and granularity
ARB [171]	Advanced reasoning ability	Specific downstream task	Multidomain advanced reasoning ability
BIG-bench [182]	Capabilities and limitations of LMs	General language task	Model performance and calibration
MultiMedQA [177]	Medical QA	Specific downstream task	Accuracy and human evaluation
CVALUES [230]	Safety and responsibility	Specific downstream task	Alignment ability of LLMs
LVLM-eHub [231]	LVLMs	Multi-modal task	Multimodal capabilities of LVLMs
ToolBench [191]	Software tools	Specific downstream task	Execution success rate
FRESHQA [198]	Dynamic QA	Specific downstream task	Correctness and hallucination
CMB [211]	Chinese comprehensive medicine	Specific downstream task	Expert evaluation and automatic evaluation
PandaLM [216]	Instruction tuning	General language task	Winrate judged by PandaLM
MINT [213]	Multi-turn interaction	Specific downstream task	Success rate with k-turn budget SR_k
Dialogue CoT [205]	In-depth dialogue	Specific downstream task	Helpfulness and acceptness of LLMs
BOSS [239]	OOD robustness in NLP	General language task	OOD robustness
MM-Vet [238]	Complicated multi-modal tasks	Multi-modal task	Integrated vision-language capabilities
LAMM [235]	Multi-modal point clouds	Multi-modal task	Task-specific metrics
GLUE-X [234]	OOD robustness for NLP tasks	General language task	OOD robustness
KoLA [236]	Knowledge-oriented evaluation	General language task	Self-contrast metrics
AGIEval [262]	Human-centered foundational models	General language task	General
PromptBench [264]	Adversarial prompt resilience	General language task	Adversarial robustness
MT-Bench [260]	Multi-turn conversation	General language task	Winrate judged by GPT-4
M3Exam [250]	Multilingual, multimodal and multilevel	Specific downstream task	Task-specific metrics
GAOKAO-Bench [245]	Chinese Gaokao examination	Specific downstream task	Accuracy and scoring rate
SafetyBench [254]	Safety	Specific downstream task	Safety abilities of LLMs
LLMEval^2 [252]	LLM Evaluator	General language task	Acc, macro-f1 and kappa correlation coefficient

四列读法

Benchmark是名称，Focus是测量焦点，Domain是领域类型，Evaluation Criteria是评价标准；表中没有模型得分。

三类组织

第4节按通用语言任务、特定下游任务和多模态任务归纳。不同基准可以重叠，也可能测同一能力的不同侧面。

读表目的

完整原表先展示，随后分三段放大。重点比较“同一模型在何种测量对象和标准下被观察”，不是记住所有名称。

表7 | PDF p.22；第4节pp.23–26 | 图表为原文；中文为汇报解读

表7放大①：知识、交互、伦理和代码各有基准

通用能力不是一项单独任务，评价标准也不统一。

Benchmark	Focus	Domain	Evaluation Criteria
SOCKET [23]	Social knowledge	Specific downstream task	Social language understanding
MME [46]	Multimodal LLMs	Multi-modal task	Ability of perception and cognition
Xiezhi [59]	Comprehensive domain knowledge	General language task	Overall performance across multiple benchmarks
Choice-75 [75]	Script learning	Specific downstream task	Overall performance of LLMs
CUAD [71]	Legal contract review	Specific downstream task	Legal contract understanding
TRUSTGPT [79]	Ethic	Specific downstream task	Toxicity, bias, and value-alignment
MMLU [70]	Text models	General language task	Multitask accuracy
MATH [72]	Mathematical problem	Specific downstream task	Mathematical ability
APPS [68]	Coding challenge competence	Specific downstream task	Code generation ability
CELLO [66]	Complex instructions	Specific downstream task	Four designated evaluation criteria
C-Eval [78]	Chinese evaluation	General language task	52 Exams in a Chinese context
EmotionBench [76]	Empathy ability	Specific downstream task	Emotional changes
OpenLLM [80]	Chatbots	General language task	Leaderboard rankings
DynaBench [94]	Dynamic evaluation	General language task	NLI, QA, sentiment, and hate speech
Chatbot Arena [128]	Chat assistants	General language task	Crowdsourcing and Elo rating system
AlpacaEval [112]	Automated evaluation	General language task	Metrics, robustness, and diversity

知识与推理

MMLU测多任务知识，MATH测数学，APPS测代码；CUAD关注合同，SOCKET关注社会知识。

交互与榜单

Chatbot Arena强调用户投票，OpenLLM提供公开比较，DynaBench关注动态评价；这些载体产生不同证据。

安全与中文

TRUSTGPT覆盖毒性、偏见与对齐，C-Eval关注中文考试。它们各有对象，不是同一个安全维度。

表7前段放大｜PDF p.22｜图表为原文；中文为汇报解读

表7放大②：工具、幻觉与领域知识进入基准体系

真实应用开始要求检索、调用、规划与责任方面的验证。

AlpacaEval [112]	Automated evaluation	General language task	Metrics, robustness, and diversity
CMMLU [108]	Chinese multi-tasking	Specific downstream task	Multi-task language understanding capabilities
HELM [114]	Holistic evaluation	General language task	Multi-metric
API-Bank [109]	Tool utilization	Specific downstream task	API call, retrieval, and planning
M3KE [122]	Multi-task	Specific downstream task	Multi-task accuracy
MMBench [126]	Large vision-language models(LVLMs)	Multi-modal task	Multifaceted capabilities of VLMs
SEED-Bench [107]	Multimodal Large Language Models	Multi-modal task	Generative understanding of MLLMs
UHGEval [116]	Hallucination of Chinese LLMs	Specific downstream task	Form, metric and granularity
ARB [171]	Advanced reasoning ability	Specific downstream task	Multidomain advanced reasoning ability
BIG-bench [182]	Capabilities and limitations of LMs	General language task	Model performance and calibration
MultiMedQA [177]	Medical QA	Specific downstream task	Accuracy and human evaluation
CVALUES [230]	Safety and responsibility	Specific downstream task	Alignment ability of LLMs
LVLM-eHub [231]	LVLMs	Multi-modal task	Multimodal capabilities of LVLMs
ToolBench [191]	Software tools	Specific downstream task	Execution success rate
FRESHQA [198]	Dynamic QA	Specific downstream task	Correctness and hallucination
CMB [211]	Chinese comprehensive medicine	Specific downstream task	Expert evaluation and automatic evaluation

综合与多模态

HELM多维评测，MMBench和SEED-Bench面向多模态；不同综合体系仍保留各自标准。

工具与动态知识

API-Bank评价API调用、检索、规划，ToolBench关注工具执行，FreshQA关注动态知识；最终答案之外还要看过程。

风险与领域

UHGEval关注中文幻觉，CVALUES关注安全责任，MultiMedQA与CMB关注医疗。任务适配是选择基准的前提。

表7放大③：OOD、提示鲁棒性与自动裁判并列存在

基准既评价模型，也可能作为评价其他模型的工具。

CMB [211]	Chinese comprehensive medicine	Specific downstream task	Expert evaluation and automatic evaluation
PandaLM [216]	Instruction tuning	General language task	Winrate judged by PandaLM
MINT [213]	Multi-turn interaction	Specific downstream task	Success rate with k-turn budget SR_k
Dialogue CoT [205]	In-depth dialogue	Specific downstream task	Helpfulness and acceptness of LLMs
BOSS [239]	OOD robustness in NLP	General language task	OOD robustness
MM-Vet [238]	Complicated multi-modal tasks	Multi-modal task	Integrated vision-language capabilities
LAMM [235]	Multi-modal point clouds	Multi-modal task	Task-specific metrics
GLUE-X [234]	OOD robustness for NLP tasks	General language task	OOD robustness
KoLA [236]	Knowledge-oriented evaluation	General language task	Self-contrast metrics
AGIEval [262]	Human-centered foundational models	General language task	General
PromptBench [264]	Adversarial prompt resilience	General language task	Adversarial robustness
MT-Bench [260]	Multi-turn conversation	General language task	Winrate judged by GPT-4
M3Exam [250]	Multilingual, multimodal and multilevel	Specific downstream task	Task-specific metrics
GAOKAO-Bench [245]	Chinese Gaokao examination	Specific downstream task	Accuracy and scoring rate
SafetyBench [254]	Safety	Specific downstream task	Safety abilities of LLMs
LLMEval² [252]	LLM Evaluator	General language task	Acc, macro-f1 and kappa correlation coefficient

鲁棒性载体

BOSS、GLUE-X关注分布外表现，PromptBench关注提示攻击；测试条件不同于普通知识题。

语言与对话

KoLA关注知识，AGIEval以人类考试为中心，MT-Bench关注多轮对话，GAOKAO-Bench与M3KE提供中文场景。

裁判类基准

PandaLM和LLMEval等使用模型评价输出。自动裁判是评价程序的一部分，需要区分模型能力与裁判能力。

通用与下游基准：先匹配问题，再谈横向比较

综合测试、标准考试与实际交互提供互补证据。

01 通用任务

HELM覆盖多维，BIG-bench含204项挑战任务；Chatbot Arena与MT-Bench强调交互，MMLU与AGIEval强调知识考试。

02 下游任务

医疗、合同、数学、代码、安全、社会知识、复杂指令分别使用专门基准；不能用考试总分代表全部部署能力。

03 工具测试

API-Bank含53种API、264段标注对话、568次调用；它提供检索和规划测试，但并不覆盖全部外部环境。

多模态基准：感知、认知与跨模态交互需要专测

视觉问答、图像视频和点云等任务不能只用文本评价替代。

01 感知与认知

MME兼顾感知、认知；MMBench采用CircularEval，试图更系统测试多模态能力；具体协议各有特点。

02 覆盖规模

SEED-Bench含约19,000道人工标注选择题，覆盖12类评价方面；LAMM进一步扩展至点云等形式。

03 解释限制

数据量大不代表所有部署环境均被覆盖。模型对视觉扰动的脆弱性与语言正确率需要分别评价。

多模态基准让模型从文本题走向视觉与其他输入。讲到题目数量时要避免把规模当作充分性，覆盖方面和真实任务匹配仍是关键。

表9：自动评价不只是准确率，还包括可信与稳定

四组指标回答“答得对、知道不确定、对群体公平、受扰动稳定”。

Table 9. Key metrics of automatic evaluation.

General metrics	Metrics
Accuracy	Exact match, Quasi-exact match, F1 score, ROUGE score [118]
Calibrations	Expected calibration error [60], Area under the curve [54]
Fairness	Demographic parity difference [242], Equalized odds difference [64]
Robustness	Attack success rate [203], Performance drop rate [264]

准确与校准

EM、近似EM、F1、ROUGE衡量任务输出；ECE与选择性准确率—覆盖率AUC关注置信度是否可靠。

公平与鲁棒

DPD、EOD关注群体预测差异；ASR、PDR衡量攻击成功或相对性能下降，两组不能与准确率互换。

指标选择

每个指标都有对象与条件。本文把能够自动计算的标准归入自动评价，包括部分语言模型裁判方案。

准确性指标：严格匹配、分类平衡与文本重叠

不同任务的“正确”，不能全部交给同一种指标。

01 EM与近似匹配

Exact Match要求输出与参考答案完全相同；近似匹配放宽形式差异。开放回答可能存在同义正确答案，严格EM会过于苛刻。

02 F1

F1=2×Precision×Recall/(Precision+Recall)。它平衡精确率和召回率；仍须说明是在分类、词项还是具体任务上计算。

03 ROUGE

ROUGE评估与参考文本的重叠，常用于摘要。高重叠可以提供质量线索，但不能独立证明全部事实正确或安全。

校准性：自信程度应该与真实正确率相匹配

模型知道自己可能出错，与模型通常答得对是不同能力。

ECE的含义

01 解释与证据

按置信度分组，比较每组平均置信度与实际正确率；常用ECE把各组差异加权汇总。越小通常表示校准越好。

选择性评价

02 解释与证据

允许只回答较有把握的样本，观察准确率与覆盖率的取舍。本文的AUC指该曲线面积，不是ROC-AUC。

实际解读

03 解释与证据

若自信90%的回答仅约60%正确，则存在过度自信；这是讲解示例，不是本文实验结果。安全场景不能忽略这种误差。

用“有九成把握的判断能否大约九成正确”解释校准。模型任务准确率和置信度可信性需要分别看。答得少但更准，也可能是一种选择性策略，因此要同时看覆盖率。

公平性：群体预测比例相同，不等于错误率相同

DPD与EOD对应不同公平定义，不能混成一个公平分数。

01 DPD

人口统计均等差异比较不同群体获得正类预测的概率。它检查输出分配比例，但不直接控制真实标签。

02 EOD

均等赔率差异（Equalized Odds Difference）比较不同群体的真阳性率与假阳性率差异；不同于仅要求真阳性率相等的均等机会。

03 解释边界

公平标准可能不同，真实群体分布与任务也重要。没有说明群体和标签口径时，单独数值不能判断系统是否公平。

鲁棒性指标：ASR看攻击转错，PDR看性能降幅

攻击成功率与相对下降需要明确分母、攻击条件和原始表现。

ASR

01 解释与证据

原文公式在原先预测正确的样本上统计攻击后变错的比例。它是条件成功率，不能不说明分母就比较不同实验。

PDR

02 解释与证据

PDR=1−攻击后任务表现/原始任务表现。它度量相对退化；若原始分数很低，相对量也可能不稳定。

使用条件

03 解释与证据

同时报告原始性能、扰动策略和测试集。高普通准确率不保证低攻击成功率，风险比较应保留完整条件。

这页是自动指标里最容易混口径的部分。ASR分母并非随意选全部样本，PDR也不是绝对百分点下降。汇报时先说明定义，再解释攻击使模型在什么条件下变差。

表10：人工评价的可信度取决于评审设计

有人评分，并不自动意味着评价更准确或更公平。

Table 10. Summary of key factors in human evaluation

Evaluation Criteria	Key Factor
Number of evaluators	Adequate representation [7], Statistical significance
Evaluation rubrics	Accuracy [178], Relevance [261], Fluency [196], Transparency, Safety [85], Human alignment
Evaluator's expertise level	Relevant domain expertise [144], Task familiarity, Methodological training

评价人数

需兼顾样本代表性和统计意义。人数不足或来源偏窄，可能让结果只反映少数人的判断。

评分规则

准确、相关、流畅、透明、安全、人类对齐形成评价量表；每个维度需要明确解释与评分标准。

评价者能力

领域知识、任务熟悉度与方法训练决定质量。专业问题不宜只凭普通用户印象评价。

人类评价的六个维度：好看、正确与安全并不相同

量表应把内容质量、交互质量和风险判断分别表达。

01 内容质量

准确性关注事实，相关性关注是否回答问题，流畅性关注表达是否顺畅；三个维度可能互相分离。

02 透明与安全

透明性在文中指回应与决策说明清晰，不等于获得真实内部机制。安全性关注不当、冒犯或有害输出。

03 人类对齐

考察人类价值、偏好与社会规范。文化和个体差异会引入评分变动，需要结合实际使用情境。

流畅性往往最容易被观察，但安全和事实需要额外核验。尤其不要把模型给出的漂亮解释称为内部机制透明。作者的人工量表关注可观察回应和使用者判断。

自动与人工结合：按任务互补，不设唯一赢家

规模化测试与开放性判断有不同成本、优势和误差。

01 自动评价

便于重复、大样本和统一计算；参考答案、指标与模型裁判仍可能遗漏开放生成的质量差异。

02 人工评价

更贴近开放回答和真实场景，但成本、文化差异、个体波动和专业性会影响一致性。

03 组合原则

按任务选择指标与人工核验，在相同条件下解释结果。本文并未证明某一种方法或基准普遍最好。

成功与失败：结论依赖数据集，不是永久能力判决

本文的总结来自已有研究；模型和服务版本更新后需要重新验证。

01 相对优势

流畅生成、情感分类、部分算术逻辑、上下文回应、翻译与问答表现较好。这些成功都带有任务条件。

02 主要失败

复杂抽象、事件语义、低资源语言、视觉扰动、毒性偏见、幻觉、实时知识与对抗提示仍显示不足。

03 正确表达

应说“某研究在某测试下发现”，不要说“本文原创实验证明”。作者在免责声明中也强调版本变化和证据边界。

表8：协议演进走向人在回路、众包与挑战测试

测试应该帮助发现失败模式，而不仅计算固定题库分数。

Table 8. Summary of new LLMs evaluation protocols.

Method	References
Human-in-the-loop	AdaVision [50], AdaTest [164]
Crowd-sourcing testing	DynaBench [94], DynaBoard [132], DynamicTempLAMA [135], DynaTask [188]
More challenging tests	HELM [114], AdaFilter [157], CheckList [165], Big-Bench [182], DeepTest [190]

人在回路

AdaVision、AdaTest允许人类标注、筛选和组织测试，帮助定位一致的失败模式。

众包与动态

DynaBench、DynaBoard、DynaTask及DynamicTempLAMA引入难例和时间更新，使测试不完全固定。

挑战测试

HELM、CheckList、DeepTest、BIG-bench等从多维、模板或变换构造挑战。更难不必然更公平，协议本身也须检验。

未来挑战①：AGI、完整行为、鲁棒与动态评测

作者要求评测跟随模型能力和应用环境共同演进。

AGI与开放行为

01 解释与证据

哪些任务能测通用智能仍未解决；需结合教育、心理、社会科学，使用开放环境中的LLM控制机器人和多模态行为测试补充标准考试。

鲁棒性

02 解释与证据

同义但语法不同的提示可能改变结果，需要更丰富测试集、更有效难例生成和不断更新的伦理偏见要求。

动态演进

03 解释与证据

静态公开基准可能被记忆，也难反映持续进步。动态测试应更新内容，但还要保证公平可比。

这里四项挑战互相连接：任务更复杂、环境更开放、输入更变化、模型持续更新，都会使固定题库不够。作者并未证明一个现成AGI基准，而是在提出未解决问题。

未来挑战②：评价系统本身也必须可信

从“测模型”进一步走向“测量工具的检验与改进闭环”。

可信评测

01 解释与证据

评测系统的完整性也要被检查；例如动态测试是否真正产生分布外样本，需要测量理论和概率支撑。

统一支撑

02 解释与证据

评价体系应支持对齐、安全、验证、微调与跨学科任务。PandaLM被用作评价与优化的例子。

超越打分

03 解释与证据

良好评价应提供失败分析、可视化与改进建议。PromptBench的注意力和词频分析帮助理解脆弱提示。

第7.5是与我们关心的评测治理最接近的原文问题：评价系统自身是否可靠。这里仅介绍作者提出的挑战，不把后续研究计划说成本文已经完成的方法。

全文结论：评价是认识能力边界与推动改进的起点

任务、基准、方法共同决定评测证据，不能用一张总榜代替全部判断。

01

本文已经完成

以what、where、how梳理任务、46个基准、自动和人工方法；综合已有文献的成功、失败和七项挑战。

02

本文没有完成

没有统一复测所有模型；没有证明一个最优基准；没有把上述总结转化为通用、长期有效的安全排名。

03

汇报讨论

读完本文应能回答：测量对象是什么、数据是否匹配、评分是否可信。进一步研究可从原文第7.3–7.5的开放问题展开。

图表完整性索引：3幅图、10张表全部进入汇报

原始编号保留；图1、表2、表7同时提供完整原图和局部放大。

01

三幅图

图1：论文结构（PDF p.3）；图2：评测论文趋势（p.5）；图3：任务—数据—过程（p.6）。全部保留原图并解释。

02

表1—表6

模型背景比较（p.6）、NLP（p.8）、安全可信（p.13）、科学工程（p.16）、医疗（p.18）、其他应用（p.20）。

03

表7—表10

46个基准（p.22）、新协议（p.26）、自动指标（p.27）、人工因素（p.29）。长表保留所有行，放大页便于讲解。